



UNIVERSIDAD MODELO
ESCUELA DE INGENIERÍA

RECONOCIMIENTO DE SEÑAS BÁSICAS DEL LSM

ASIGNATURA

VISIÓN POR COMPUTADORA

CARRERA

INGENIERÍA MECATRÓNICA

7° SEMESTRE

PROFESOR

DR. RUBEN RENAN RAYGOSA BARAHONA

ALUMNO

PÉREZ ONGAY ÁNGEL GABRIEL

CURSO ESCOLAR

AGOSTO 2026 – DICIEMBRE 2026

FECHA

20 de Septiembre de 2026

1. INTRODUCCIÓN

1.1. Contexto y Planteamiento del Problema

El reconocimiento automático de posturas manuales y gestos articulares constituye uno de los desafíos más representativos dentro del área de la visión por computadora y el reconocimiento de patrones. A diferencia del procesamiento de formas rígidas o predecibles, la mano humana se caracteriza por poseer un espacio de búsqueda cinemático complejo con más de 20 grados de libertad, lo que genera una alta variabilidad geométrica, susceptibilidad a auto-oclusiones entre falanges y transformaciones no lineales en el plano bidimensional de proyección de la cámara. El problema específico abordado en este trabajo es la clasificación y reconocimiento en tiempo real del alfabeto dactilológico de la Lengua de Señas Mexicana (LSM) a partir de una secuencia continua de video. La dactilología manual se compone de configuraciones espaciales estáticas y dinámicas de los dedos, la palma y el pulgar, donde variaciones mínimas en la flexión interfalángica o en la abducción de una falange diferencian clases ortográficas completamente distintas.

1.2. Justificación del Uso de Visión por Computadora

Históricamente, la captura de la cinemática articular de la mano requería el acoplamiento de interfaces físicas invasivas. Si bien estos transductores adquieren directamente las lecturas angulares, introducen restricciones de calibración estática, derivas térmicas y una dependencia estricta de hardware periférico dedicado. La visión por computadora ofrece una solución no invasiva, permitiendo extraer la información únicamente a partir del sensor óptico convencional. Dentro del estado del arte para la clasificación de configuraciones manuales coexisten dos paradigmas técnicos fundamentales:

1.2.1. Clasificación Basada en Imágenes Completas mediante Redes Neuronales Convolucionales (CNN):

Siguiendo el esquema clásico de arquitecturas para visión artificial, el modelo toma directamente tensores de píxeles en escala de. A través de capas sucesivas de convolución espacial, funciones de activación no lineales y submuestreo, la red sintetiza mapas de características de bordes, gradientes y texturas. No obstante, este paradigma presenta limitaciones críticas cuando se busca inferencia ligera: es sensible a las características del fondo, requiere un volumen masivo de datos para

generalizar ante variaciones de iluminación y demanda un costo computacional de cálculo tensorial que eleva la latencia si no se cuenta con aceleración gráfica.

1.2.2. Pipeline Basado en Estimación de Poses Anatómicas (Landmarks) y Clasificación

Geométrica:

Este enfoque desacopla el problema en dos etapas algorítmicas secuenciales:

- **Detección y Regresión Espacial:** Utilizando modelos de regresión espacial pre-entrenados y optimizados para dispositivos de borde, se detectan y proyectan las coordenadas tridimensionales normalizadas.
- **Inferencia Ligera sobre Descriptores Vectoriales:** Al colapsar una imagen densa de cientos de miles de píxeles a un vector numérico estructurado de características continuas, la tarea de clasificación se transfiere a modelos matemáticos de alta eficiencia computacional y bajo consumo de memoria, tales como ensambles de árboles de decisión.

La comparativa y experimentación sobre estas dos filosofías de diseño permite evaluar rigurosamente el compromiso de ingeniería entre costo computacional, precisión y estabilidad temporal en condiciones de operación real.

1.3. Objetivos del Proyecto

1.3.1. Objetivo General

Desarrollar, implementar y validar experimentalmente un sistema de visión por computadora para el reconocimiento en tiempo real del alfabeto dactilológico de la Lengua de Señas Mexicana (LSM) mediante cámara web, analizando cuantitativamente el rendimiento y la latencia computacional entre una arquitectura convolucional directa y un pipeline geométrico basado en puntos articulares.

1.3.2. Objetivos Específicos

1. **Adquisición, Procesamiento y Normalización de Características.**
2. **Implementación y Entrenamiento de Modelos.**
3. **Evaluación Cuantitativa y Diagnóstico.**
4. **Despliegue e Inferencia en Tiempo Real.**

2. METODOLOGÍA

2.1. Adquisición y Naturaleza del Dataset

Para sustentar la comparativa técnica entre los dos paradigmas de visión por computadora abordados en este trabajo, se emplearon dos fuentes de datos con representaciones espaciales y formatos estructurados distintos:


Dataset Matricial para Red Convolutiva (Sign Language MNIST):

- **Estructura y Dimensiones:** Consta de imágenes en escala de grises con una resolución espacial fija de 28×28 píxeles.
- **Distribución de Clases:** El conjunto abarca 24 clases correspondientes a las letras del alfabeto dactilológico en posturas estáticas (se excluyen las letras 'J' y 'Z' por requerir una trayectoria de movimiento). El conjunto de entrenamiento contiene aproximadamente 27,455 muestras, mientras que el conjunto de prueba independiente (*test*) cuenta con 7,172 muestras etiquetadas.



Dataset Vectorial Tabular de Lengua de Señas Mexicana (LSM):

- **Estructura de Características:** A diferencia del enfoque basado en píxeles, este conjunto de datos está constituido por vectores de descriptores geométricos extraídos mediante el detector de poses anatómicas *MediaPipe Hands*.
- **Dimensionalidad:** Cada registro en el dataset almacena las coordenadas tridimensionales de 21 puntos articulares clave. Cada punto contiene coordenadas (x_i, y_i, z_i) , conformando un vector tabular continuo de entrada con una dimensionalidad total de $D = 21 \times 3 = 63$ características numéricas por muestra.



2.2. Preprocesamiento e Ingeniería de Características

A. Preprocesamiento del Dataset Matricial (CNN)

1. **Remodelado Tensorial (Reshaping):** El vector plano de 784 valores fue transformado a un tensor tridimensional con forma compatible con capas de convolución 2D: (28,28,1).

2. **Normalización Min-Max:** Las intensidades de los píxeles fueron escaladas algebraicamente desde el intervalo entero $[0,255]$ al rango continuo de coma flotante $[0.0,1.0]$

B. Ingeniería de Características de LSM (Random Forest)

La simple captura de coordenadas absolutas en píxeles genera una fuerte dependencia de la posición de la mano respecto al lente. Para lograr invarianza espacial, se ejecutó un pipeline de ingeniería de características sobre los 21 puntos de MediaPipe:

Partición Formal de Datos (Train / Test Split): El conjunto vectorial procesado fue dividido mediante un muestreo aleatorio estratificado en un 80% para entrenamiento (*Train*) y un 20% para evaluación independiente (*Test Holdout*).

2.3. Arquitectura del Modelo Convolucional (CNN):

Para este modelo usamos la misma lógica que en las prácticas de clase con la ropa (Fashion-MNIST) y los números escritos a mano (MNIST).

Básicamente, la red funciona como una serie de filtros o "lupas" que van revisando la foto de la mano por pedacitos:

- **Primeras capas:** Detectan cosas muy simples, como las líneas rectas de los dedos, los bordes de la mano y los contrastes de luz.
- **Capas intermedias:** Juntan esas líneas para entender formas más completas, como si un dedo está doblado, estirado o haciendo un círculo.
- **Capas finales:** Juntan todas las piezas del rompecabezas y deciden a qué letra se parece más la foto.

Para evitar que la red hiciera trampa y se memorizara las imágenes de memoria (*overfitting*), le apagamos neuronas al azar durante el entrenamiento (*Dropout*) y le pusimos un freno automático (*Early Stopping*) para que se detuviera solita apenas dejara de mejorar.

2.4. Arquitectura y Selección del Modelo Random Forest:

Para las señas mexicanas con MediaPipe, en lugar de meterle toda la foto pesada a una red neuronal, usamos **Random Forest** (Bosque Aleatorio).

- **¿Por qué este modelo?** MediaPipe ya hizo el trabajo pesado de encontrar los 21 puntos de la mano. En lugar de procesar miles de píxeles, solo le pasamos una lista corta de números (las coordenadas de las articulaciones). Procesar números en una tabla es el fuerte de los árboles de decisión.
- **¿Cómo funciona?** Es como tener un comité de 100 "árboles" o jueces expertos. Cada árbol revisa las posiciones de los dedos y hace preguntas lógicas del tipo: *¿el pulgar está arriba del índice?*, *¿el meñique está doblado?*, *¿los dedos están separados?*. Al final, los 100 árboles votan y la letra que junte más votos es la que se muestra en pantalla. Esto corre rapidísimo en cualquier computadora normal sin trabarse.

2.5. Pipeline de Inferencia en Tiempo Real:

Este es el camino que sigue el programa desde que prendes la cámara hasta que ves la letra:

1. **Prende la webcam:** Abre la cámara y voltea la imagen como si fuera un espejo, para que cuando muevas tu mano a la derecha, en la pantalla se mueva a la derecha y no te confundas.
2. **MediaPipe busca tu mano:** Escanea la imagen y le dibuja encima una especie de "esqueleto" verde con 21 puntitos en las articulaciones.
3. **Acomoda las coordenadas:** Si mueves la mano por toda la pantalla, las coordenadas cambian. Por eso, el código resta la posición de la muñeca para que la mano siempre quede centrada en su propio punto cero, sin importar si estás en la esquina o al centro.
4. **Predice y estabiliza:** Le pasa esos puntos al modelo para que adivine la letra. Para que la letra no esté parpadeando o cambiando a lo loco si te tiembla tantito el dedo, el programa promedia las últimas 5 lecturas antes de cambiar el texto.
5. **Muestra el resultado:** Pone en la pantalla un letrero grande con la letra detectada y qué tan seguro está el programa (por ejemplo: *"Letra: A (95%)"*). Si la mano no está clara o duda mucho, simplemente no se arriesga a poner nada raro.

3. RESULTADOS

3.1. Evaluación Cuantitativa Global:


Se evaluaron de manera independiente ambos enfoques sobre sus respectivos conjuntos de prueba (*test split*), garantizando que las métricas reflejen la capacidad de generalización ante muestras nunca antes vistas por los algoritmos durante la fase de entrenamiento.

<i>Métrica / Parámetro</i>	<i>Enfoque 1: CNN (Sign Language MNIST)</i>	<i>Enfoque 2: Random Forest (MediaPipe LSM)</i>
<i>Representación de entrada</i>	Tensor denso de píxeles ($28 \times 28 \times 1$)	Vector de 21 <i>landmarks</i> 3D (63 atributos)
<i>Muestras de prueba (Test)</i>	7,172 imágenes	230 instancias dactilológicas
<i>Exactitud Global (Accuracy)</i>	99.68%	92.61%
<i>Precisión Macro (Precision)</i>	99.68%	93.30%
<i>Sensibilidad Macro (Recall)</i>	99.61%	92.61%
<i>Puntuación F_1 Macro</i>	99.63%	92.59%
<i>Latencia promedio de inferencia (CPU)</i>	~18 – 25 ms por cuadro	~2 – 4 ms por cuadro
<i>Tasa de refresco en vivo (Webcam)</i>	No aplicable directamente (requiere recorte)	30 FPS estables

3.2. Curvas de Aprendizaje y Dinámica de Entrenamiento (CNN)

El entrenamiento de la red neuronal convolucional se ejecutó a lo largo de 25 épocas completas, monitoreando en cada iteración la función de pérdida categórica (*loss*) y la precisión (*accuracy*) tanto en el conjunto de entrenamiento como en el de validación.

- **Evolución de la Función de Pérdida (*Loss*):** Se observa una reducción monotónica pronunciada desde la época 0 hasta la época 5, donde el error de entrenamiento desciende desde un valor inicial de 2.21 hasta estabilizarse por debajo de 0.15. La curva de validación acompaña esta trayectoria sin divergencias significativas, alcanzando un valor asintótico cercano a cero (< 0.02) a partir de la época 10, lo que evidencia ausencia de sobreajuste crítico.
- **Evolución de la Exactitud (*Accuracy*):** El modelo exhibe una convergencia acelerada, superando el 85% de exactitud desde la segunda época y alcanzando una meseta de estabilidad a partir de la época 8, donde la métrica en validación roza el 100%.




3.3. Análisis de la Matriz de Confusión:

A. Matriz de Confusión — Red Convolucional (Sign Language MNIST)

La matriz de confusión obtenida sobre las 7,172 muestras de prueba demuestra una concentración casi absoluta sobre la diagonal principal:

- **Rendimiento por clase:** 22 de las 24 clases evaluadas alcanzaron una exactitud del 100% en la clasificación de sus muestras de prueba correspondientes.

- **Patrón de dispersión detectado:** La única desviación relevante se localiza en la **letra 'T'**, donde 21 de las 248 instancias reales fueron clasificadas erróneamente como **'X'**, además de 2 muestras de la **letra 'S'** asignadas a la **letra 'M'**. Esto se atribuye a que, en representaciones monocromáticas de baja resolución (28×28), la silueta perimetral de un puño cerrado con el pulgar insertado entre el índice y el medio ('T') proyecta bordes y sombras muy similares a un dedo índice flexionado en gancho ('X').




B. Matriz de Confusión — Random Forest con MediaPipe (LSM)

La evaluación sobre las 230 muestras de prueba de Lengua de Señas Mexicana evidencia el comportamiento del clasificador basado en coordenadas anatómicas:

- **Clases con acierto perfecto (10/10 muestras correctas):** Las letras **B, G, I, L, P, Q, S, U, W, X** e **Y** alcanzaron un 100% de precisión y sensibilidad, debido a que presentan configuraciones espaciales abiertas y distintivas (por ejemplo, extensión aislada del meñique en 'I', configuración en 'L' o extensión tridigital en 'W').

- **Confusiones anatómicas específicas:**

- **'M' vs. 'N':** Se registraron 2 instancias de 'M' clasificadas como 'N' y 1 instancia de 'N' clasificada como 'M'. Ambas señas consisten en un puño cerrado donde la única diferencia es si el pulgar asoma por debajo de tres dedos ('M') o de dos dedos ('N'). Las oclusiones entre falanges provocan que MediaPipe estime profundidades relativas (z) casi idénticas.
- **'H' vs. 'G':** 2 muestras de la seña 'H' se confundieron con 'G'. En ambas posturas la mano se orienta horizontalmente; la transición entre mantener extendido solo el índice ('G') o el índice junto al medio ('H') suele cerrarse en la vista frontal de la cámara web.
- **'V' vs. 'U':** 2 muestras de 'V' fueron predichas como 'U'. La configuración dactilar es idéntica (índice y medio extendidos verticalmente), diferenciándose únicamente por el ángulo de abducción/separación entre ambos dedos.
- **'T' vs. 'R' / 'S':** Se presentó una dispersión de 1 error hacia 'R' y 1 hacia 'S', explicada por la compresión de los nudillos en posturas de puño cerrado.



4. COMENTARIOS Y DISCUSIÓN

4.1 Análisis Crítico: Imágenes Densas (CNN) vs. Descriptores Geométricos (MediaPipe)

La comparativa entre los dos paradigmas implementados permite extraer conclusiones de ingeniería determinantes para sistemas de visión artificial aplicados:

4.1.1 *La paradoja de las métricas en papel frente a la realidad operativa:*

La Red Neuronal Convolutiva (CNN) obtuvo una exactitud casi perfecta en el conjunto de prueba (99.68%). Sin embargo, esta cifra es representativa únicamente dentro del dominio cerrado de imágenes. Al trasladar este modelo a un flujo de video real por cámara web, el sistema colapsa ante cualquier variación en la textura del fondo, cambios de escala por distancia a la cámara o tonos de piel no representados.

Por el contrario, el pipeline de MediaPipe + Random Forest, a pesar de reportar un 92.61% en test, demostró ser la arquitectura verdaderamente funcional y robusta para inferencia en tiempo real. Al desacoplar la localización espacial de la mano de la tarea de clasificación, el modelo trabaja exclusivamente con una abstracción geométrica de 63 variables continuas, volviéndose 100% inmune al color de fondo, la iluminación ambiental o la ropa del usuario.

4.2. Análisis de Limitaciones y Casos de Falla:

A partir del análisis detallado de la matriz de confusión y las pruebas en vivo con cámara web, se identificaron los principales factores que inducen errores en el sistema:

1. *El problema de la auto-oclusión (Pérdida de la tercera dimensión z):*

Las mayores confusiones del modelo ocurrieron en letras de mano cerrada: 'M' vs. 'N' (donde el pulgar queda oculto bajo los dedos flexionados) y 'T' vs. 'S'. Al capturar la escena con una cámara web monocular estándar (2D), MediaPipe debe estimar la coordenada de profundidad (z) mediante regresión estadística a partir de proporciones anatómicas, lo que provoca imprecisiones cuando un dedo oculta a otro en la línea de visión del lente.

2. Proximidad angular y ambigüedad geométrica:

La confusión entre 'V' y 'U' (2 casos) evidencia la sensibilidad del modelo a la separación de los dedos: una persona con dedos más gruesos o menor flexibilidad para abrir el índice y el medio puede ser catalogada erróneamente como 'U' al intentar realizar una 'V'. De igual forma, la postura horizontal de 'H' frente a 'G' sufre por la orientación de la mano respecto al eje de la cámara.

3. La barrera de las señas dinámicas:

Tanto la CNN como el Random Forest operan bajo una lógica estática (cuadro a cuadro). Letras como la 'J' y la 'Z' en la Lengua de Señas Mexicana requieren trazar una trayectoria en el espacio (un gancho descendente o un zigzag). Estas letras no pueden ser resueltas con clasificadores espaciales puros, requiriendo necesariamente análisis de secuencias temporales.

4.3. Respuestas a Preguntas de Defensa Oral:

➤ ¿Por qué utilizar Random Forest en lugar de una red densa (MLP) para los landmarks?

Respuesta técnica: Los árboles de decisión y los ensambles tipo Random Forest son notoriamente superiores y más estables que las redes neuronales densas cuando se trabaja con datos tabulares de pocas dimensiones ($D = 63$). No requieren normalizaciones complejas de gradiente, son inmunes a problemas de desvanecimiento de gradiente, no sufren fácilmente de sobreajuste con muestras moderadas y ofrecen tiempos de predicción prácticamente instantáneos sin requerir hiperparámetros de aprendizaje complejos.

➤ ¿Por qué fue indispensable la normalización relativa a la muñeca?

Respuesta técnica: Si se alimentan las coordenadas directas que entrega la cámara, el modelo aprendería a asociar una letra con una posición específica de la pantalla (por ejemplo, "la letra A se hace en la esquina superior izquierda"). Al restar la coordenada (x_0, y_0, z_0) de la muñeca a todos los puntos, se logra invarianza traslacional, permitiendo al usuario comunicarse con soltura en cualquier parte del encuadre.

➤ *¿Qué función cumple el filtro de suavizado temporal en la webcam?*

Respuesta técnica: En visión por computadora en vivo, las fluctuaciones de iluminación o pequeños temblores musculares provocan que las coordenadas oscilen ligeramente entre cuadro y cuadro. El filtro de promedio móvil sobre una ventana de 5 cuadros actúa como un filtro pasabajas, eliminando el parpadeo (*flickering*) en pantalla y entregando una experiencia visual estable para el usuario final.

4.4. Trabajo Futuro

Para evolucionar el prototipo hacia una herramienta de asistencia integral, se proponen las siguientes líneas de desarrollo:

1. **Modelado de Trayectorias Temporales:** Incorporar una red neuronal recurrente (LSTM o GRU) o un modelo de Transformers para capturar secuencias de fotogramas, permitiendo reconocer las letras dinámicas ('J', 'Z') y pasar del deletreo dactilológico al reconocimiento de palabras y frases completas en LSM.
2. **Normalización por Envergadura de Palma (Invarianza a la Escala):** Además de centrar respecto a la muñeca, dividir todas las distancias entre la longitud de la palma (distancia euclidiana entre la muñeca y la articulación base del dedo medio), lo que garantizará que el sistema funcione con la misma precisión para manos de niños o adultos independientemente de qué tan cerca o lejos se coloquen del sensor.

5 REFERENCIAS

- ❖ **G. Escamilla**, «TRADUCTOR_LSM: Dataset de puntos articulares (landmarks) y herramientas para Lengua de Señas Mexicana», Repositorio GitHub, 2023. [En línea]. Disponible en: [\[https://github.com/gabescamilla2-sketch/TRADUCTOR_LSM\]](https://github.com/gabescamilla2-sketch/TRADUCTOR_LSM)(https://github.com/gabescamilla2-sketch/TRADUCTOR_LSM).
- ❖ **Tecscene**, «Sign Language MNIST: Hand gesture recognition dataset for sign language letters in 28×28 grayscale format», Kaggle, 2017. [En línea]. Disponible en: [\[https://www.kaggle.com/datasets/datamunge/sign-language-mnist\]](https://www.kaggle.com/datasets/datamunge/sign-language-mnist)(<https://www.kaggle.com/datasets/datamunge/sign-language-mnist>).
- ❖ **F. Zhang, V. Bazarevsky, A. Vakunov, A. Tkachenka, G. Sung, C.-L. Chang, y M. Grundmann**, «MediaPipe Hands: On-device Real-time Hand Tracking», *arXiv preprint arXiv:2006.10214*, 2020.
- ❖ **L. Breiman**, «Random Forests», *Machine Learning*, vol. 45, n.º 1, pp. 5–32, 2001.

6 ANEXOS

Anexo A: Github del Proyecto

<https://github.com/ZaHandoOG/Reconocimiento-de-se-as-b-sicas-del-alfabeto-LSM>

Anexo B: Comparación de Modelos

